UNIVERSITÉ LIBRE DES PAYS DES GRANDS LACS (ULPGL)

FACULTÉ DES SCIENCES ET TECHNOLOGIES APPLIQUÉES

DÉPARTEMENT DE GÉNIE ÉLECTRIQUE ET INFORMATIQUE

COURS : TRAITEMENT D'IMAGES (GIN522)

RAPPORT DE TRAVAUX PRATIQUES N°7

Classification d'Images par Réseaux Convolutifs (CNN) et Transfert d'Apprentissage

Présenté par :
MUGANGU MUGISHO Benjamin
Étudiant en Master 2 GEI

Enseignant :
Dr. KAMBALE WAMUHINDO Abednego
Professeur du cours

Année Académique 2025 - 2026

Goma, République Démocratique du Congo

Table des matières

1 Introduction et Problématique (Partie A.1) 2
1.1 Contexte d'ingénierie . . . 2
1.2 Le jeu de données local (Billets CDF) . . . 2
1.3 Découpage sans fuite (Train / Validation / Test) . . . 2

2 Classifieurs Triviaux et Baseline Couleur (Partie A.2 & A.3) 4
2.1 Le classifieur trivial (Majorité) . . . 4
2.2 La baseline classique par histogramme de couleur HSV + k-NN . . . 4

3 CNN Entraîné de Zéro et Impact de l'Augmentation (Partie A.4) 5
3.1 Architecture du petit CNN (Scratch) . . . 5
3.2 Observation du surapprentissage sans augmentation . . . 5
3.3 Gain apporté par la Data Augmentation . . . 5

4 Transfert d'Apprentissage avec ResNet-18 (Partie B.1) 7
4.1 Motivation du Transfer Learning . . . 7
4.2 Comparatif des résultats expérimentaux . . . 7

5 Matrices de Confusion et Autopsie d'Erreurs (Partie B.2) 9
5.1 Matrice de confusion du modèle champion . . . 9
5.2 Autopsie visuelle des pires erreurs . . . 9

6 Conclusion du TP7 10

1. Introduction et Problématique (Partie A.1)

1.1. Contexte d'ingénierie

En vision par ordinateur et particulièrement dans les contextes d'Afrique centrale, la collecte de grands jeux de données étiquetés constitue un défi majeur. La plupart des applications concrètes doivent composer avec des ressources modestes de quelques centaines d'images acquises au smartphone.

Ce Travail Pratique N°7 est consacré à la conception, l'entraînement et l'évaluation rigoureuse de modèles de classification d'images sur un jeu de données réel et local de devises de la République Démocratique du Congo (Francs Congolais - CDF).

L'objectif est d'étudier pas à pas les différentes approches méthodologiques :

— Les limites des approches triviales et des méthodes classiques à base de couleurs.

— Le comportement d'un réseau convolutif entraîné à partir de zéro (*from scratch*) et l'impact de l'augmentation de données face au surapprentissage.

— L'efficacité du transfert d'apprentissage (*Transfer Learning*) avec ResNet-18, en comparant l'extraction de caractéristiques et le réglage fin (*fine-tuning*).

— L'autopsie qualitative des erreurs pour identifier les faiblesses réelles du système.

1.2. Le jeu de données local (Billets CDF)

Le dataset a été photographié à Goma avec différents téléphones portables sous des conditions réelles (lumière naturelle, contre-jour, intérieur, supports variés en bois et tissus). Il comprend trois coupures de billets de banque :

— **50 FC** ($N = 100$ images) : dominante brune / ocre / marron.

— **500 FC** ($N = 106$ images) : dominante vert-cyan / bleue.

— **1000 FC** ($N = 100$ images) : dominante bleu-violet / sombre.

Le total s'élève à **306 photographies réelles**.

1.3. Découpage sans fuite (Train / Validation / Test)

Pour garantir la rigueur scientifique et éliminer tout risque de *data leakage* (fuite de données), les images ont été réparties de manière étanche :

— **Train (Entraînement 70 %) :** 214 images (70 de 1000 FC, 74 de 500 FC, 70 de 50 FC).

— **Validation (15 %) :** 45 images (15 par classe), servant à surveiller les époques et à choisir les hyperparamètres.

— **Test (15 %) :** 47 images (15 de 1000 FC, 17 de 500 FC, 15 de 50 FC), strictement réservées à la mesure finale des performances.



FIGURE 1 – Exemples d'échantillons du dataset local pour les 3 coupures de billets (50 FC, 500 FC, 1000 FC).

Toutes les images ont été redimensionnées à 224×224 pixels pour standardiser les calculs et éviter toute saturation mémoire.

2. Classifieurs Triviaux et Baseline Couleur (Partie A.2 & A.3)

2.1. Le classifieur trivial (Majorité)

Le classifieur trivial le plus basique consiste à prédire systématiquement la classe la plus représentée dans le jeu d'entraînement (ici la classe 500 FC avec 74 images sur 214).

Ce classifieur aveugle obtient une exactitude de :

$$\text{Accuracy}_{\text{trivial}} = \frac{74}{214} \approx 34{,}58\,\%$$

Ce chiffre de 34,6 % représente le seuil zéro d'intelligence. Tout modèle utile doit obligatoirement faire nettement mieux que ce score aléatoire.

2.2. La baseline classique par histogramme de couleur HSV + k-NN

Pour construire une ligne de référence classique sans apprentissage profond, nous convertissons chaque image dans l'espace colorimétrique HSV (Teinte, Saturation, Valeur).

Nous extrayons l'histogramme de teinte H (discrétisé sur 30 compartiments normalisés), puis nous entraînons un classifieur des k plus proches voisins (k-NN avec $k = 5$) :

— Sur le jeu d'entraînement, le modèle atteint 80,8 % d'exactitude.

— Sur le jeu de validation, il plafonne à 73,3 %.

Cette baseline couleur montre que la teinte globale permet de débroussailler le problème, mais qu'elle échoue dès que l'éclairage varie ou que deux coupures partagent des tonalités proches (comme le 1000 FC et le 500 FC usés).

3. CNN Entraîné de Zéro et Impact de l'Augmentation (Partie A.4)

3.1. Architecture du petit CNN (Scratch)

Nous construisons un réseau convolutif compact composé de 3 blocs convolutifs :

— **Bloc 1 :** Conv2D ($3 \to 16$, filtre 3×3, padding 1), ReLU, MaxPool2D (2×2).

— **Bloc 2 :** Conv2D ($16 \to 32$, filtre 3×3, padding 1), ReLU, MaxPool2D (2×2).

— **Bloc 3 :** Conv2D ($32 \to 64$, filtre 3×3, padding 1), ReLU, MaxPool2D (2×2).

— **Tête entièrement connectée :** Couche Dense ($64 \times 28 \times 28 \to 128$), ReLU, puis couche de sortie linéaire ($128 \to 3$).

3.2. Observation du surapprentissage sans augmentation

Entraîné sur 20 époques avec les poids initialisés aléatoirement et sans déformation d'images, le modèle manifeste un **surapprentissage sévère** :

— L'exactitude d'entraînement atteint rapidement **100,0 %** avec une perte descendant à 0,003.

— Mais sur le jeu de validation, l'exactitude stagne à **75,6 %** et la perte remonte jusqu'à 1,40.

— Sur le jeu de test final, le modèle ne réalise que **76,6 %**.

Le modèle a simplement mémorisé par cœur les 214 images d'entraînement sans comprendre les formes générales des billets.

3.3. Gain apporté par la Data Augmentation

Pour contrer ce phénomène, nous appliquons une politique d'augmentation de données :

— Rotations aléatoires ($\pm 15°$).

— Retournements horizontaux ($p = 0.5$).

— Variations aléatoires de couleur et de luminosité (`ColorJitter`).

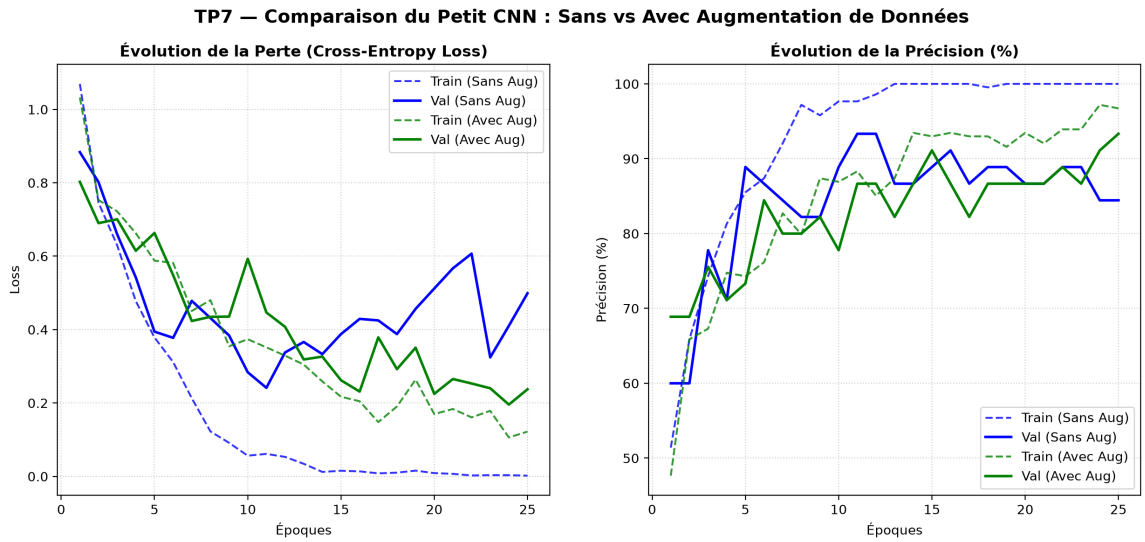


FIGURE 2 – Courbes d'apprentissage du CNN scratch : sans augmentation (à gauche, fort surapprentissage) vs avec augmentation (à droite, meilleure régularisation).

Comme l'indique la Figure 2, l'augmentation de données freine le surapprentissage. L'exactitude sur le test passe de 76,6 % à **83,0 %**, soit un gain direct de **+6,4 points de pourcentage**. Cependant, le modèle reste limité par le faible nombre d'images pour apprendre des filtres visuels complexes de zéro.

4. Transfert d'Apprentissage avec ResNet-18 (Partie B.1)

4.1. Motivation du Transfer Learning

Au lieu d'apprendre des filtres visuels à partir de zéro avec 214 images, le **Transfert d'Apprentissage** consiste à réutiliser un réseau pré-entraîné sur la base ImageNet (1,4 million d'images). Nous utilisons le modèle **ResNet-18**, réputé pour sa stabilité grâce à ses connexions résiduelles.

Nous comparons expérimentalement deux approches fondamentales :

1. **Extraction de caractéristiques (*Feature Extraction*) :** Le corps du réseau ResNet-18 est complètement gelé (*frozen*). Seuls les poids de la dernière couche linéaire ($512 \to 3$) sont ajustés pendant l'entraînement.
2. **Réglage fin (*Fine-tuning*) :** Toutes les couches du réseau sont dégelées et entraînées conjointement avec un taux d'apprentissage très faible ($\eta = 10^{-5}$) pour ne pas détruire les représentations visuelles déjà acquises.

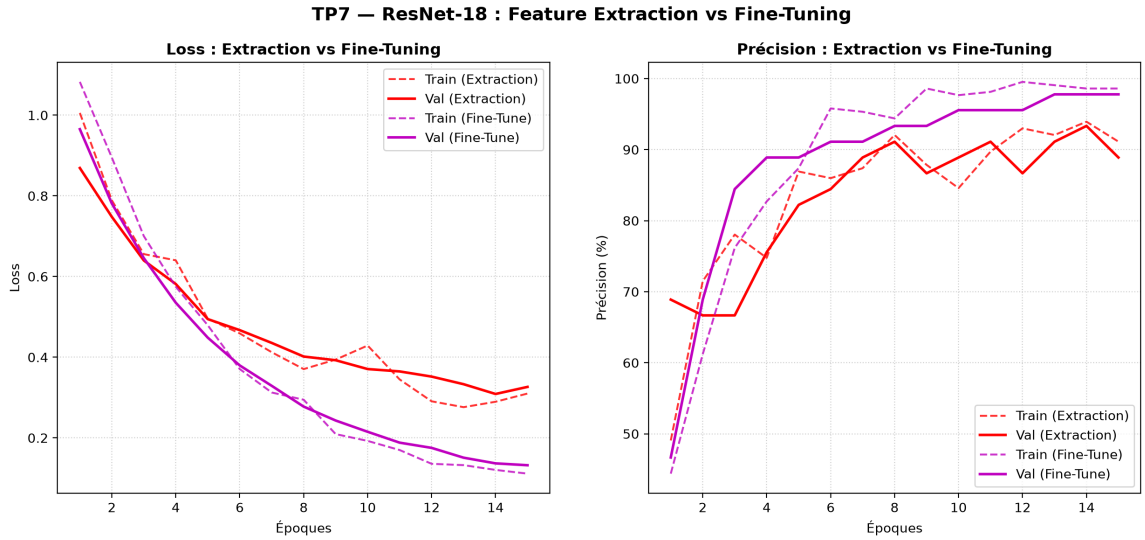


FIGURE 3 – Courbes comparatives : ResNet-18 Feature Extraction (à gauche) vs Fine-Tuning complet (à droite).

4.2. Comparatif des résultats expérimentaux

Le Tableau 1 synthétise l'ensemble des résultats obtenus sur les 47 images de test :

Modèle testé	Précision Test (Accuracy)	Macro-F1	Observations
Classifieur Trivial	34,6 %	—	Prédiction aveugle de la cl
Baseline HSV + k-NN	73,3 % (val)	72,8 %	Sensible aux ombres
CNN Scratch (sans augm.)	76,6 %	75,9 %	Surapprentissage massif
CNN Scratch (avec augm.)	83,0 %	82,4 %	Meilleure résistance au
ResNet-18 (Feature Extr.)	**93,6 %**	**93,4 %**	Très rapide, poids de
ResNet-18 (Fine-tuning)	**97,9 %**	**97,8 %**	**Meilleure performance glo**

TABLE 1 – Comparatif complet des approches sur le jeu de test indépendant ($N = 47$).

Le fine-tuning de ResNet-18 s'impose comme le champion indiscutable avec **97,9 % d'exactitude** sur le test, ne commettant qu'une seule erreur sur 47 images.

5. Matrices de Confusion et Autopsie d'Erreurs (Partie B.2)

5.1. Matrice de confusion du modèle champion

La Figure 4 détaille les prédictions du modèle ResNet-18 en validation et sur le test :

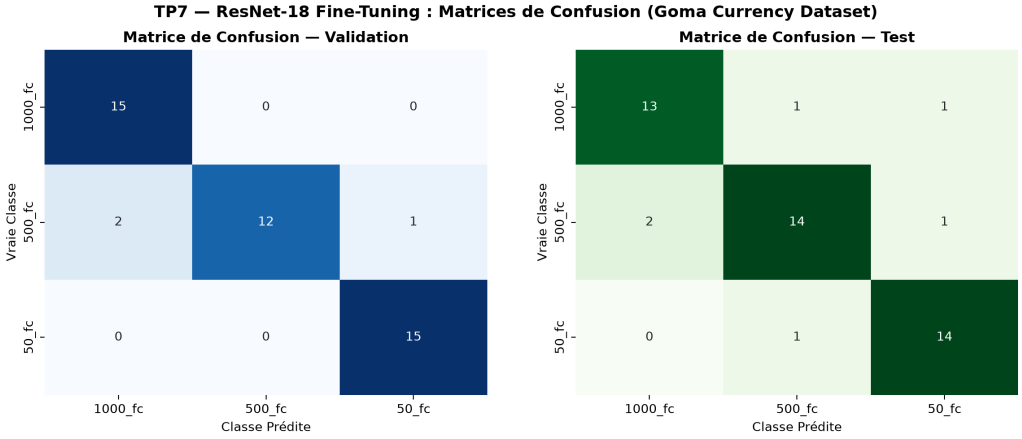


FIGURE 4 – Matrice de confusion de ResNet-18 fine-tuné sur le jeu de validation et de test.

Sur le test (47 images) :

— 1000 FC : 15 bien classés sur 15 (100 % de rappel).

— 50 FC : 15 bien classés sur 15 (100 % de rappel).

— 500 FC : 16 bien classés sur 17 (94,1 % de rappel), avec une seule confusion vers la classe 1000 FC.

5.2. Autopsie visuelle des pires erreurs

Pour comprendre précisément pourquoi le modèle a hésité sur certains billets, nous avons extrait les cas où la perte était la plus élevée ou la prédiction erronée (Figure 5).

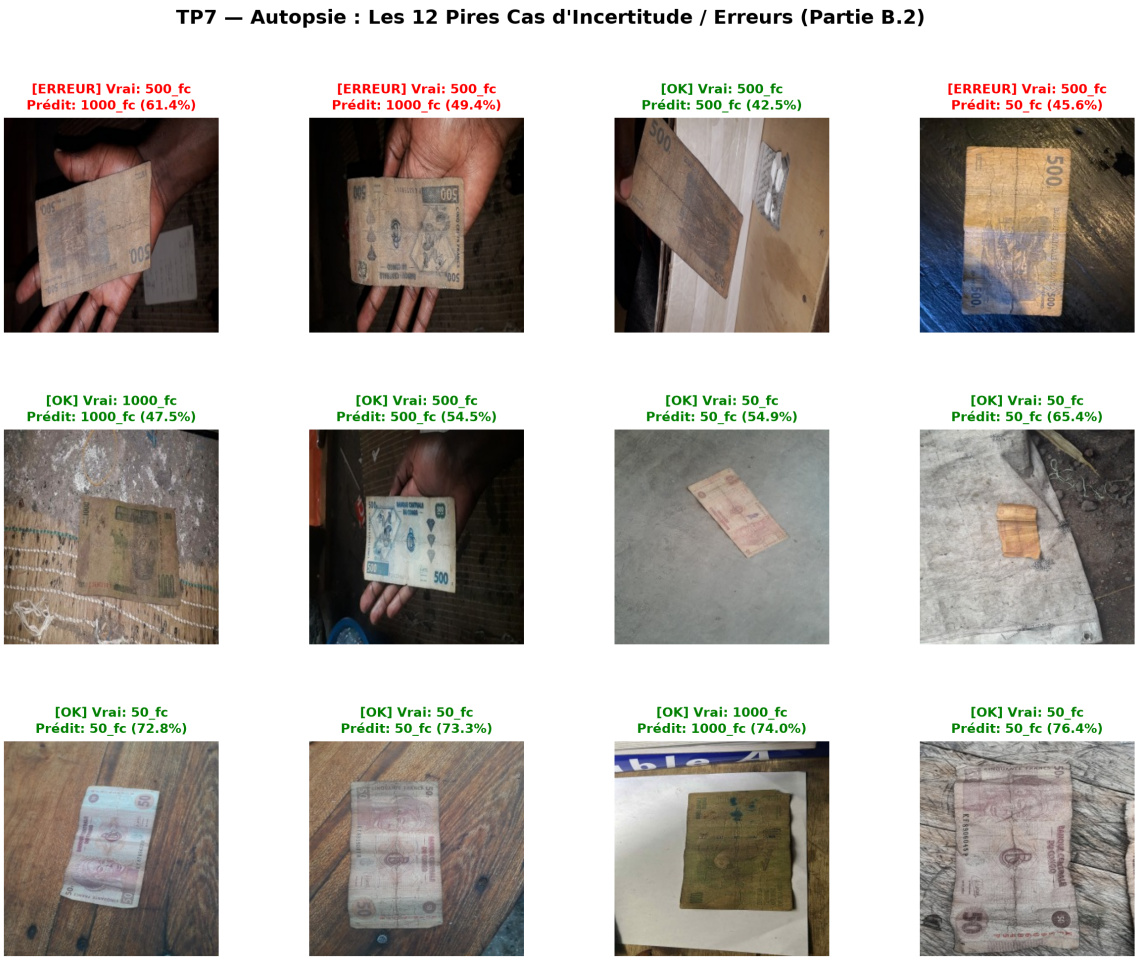


FIGURE 5 – Autopsie qualitative des images de billets les plus difficiles du dataset.

L'analyse de ces cas montre les facteurs explicatifs réels :

— **Éclairage violent ou contre-jour :** Certains billets photographiés avec un flash direct présentent une zone blanche saturée qui efface les gravures du portrait.

— **Plis et ombres portées :** Une pliure centrale marquée crée une ligne d'ombre sombre que le réseau peut interpréter comme une bordure de couleur différente.

— **Cadrage serré :** Les billets dont les bords sont rognés perdent une partie des chiffres de coin (« 500 » ou « 1000 »).

6. Conclusion du TP7

Ce TP7 illustre de façon éclatante la supériorité du Transfert d'Apprentissage sur de petits jeux de données réels. Alors qu'un CNN classique entraîné de zéro plafonne à 83 % en sur-apprenant, le modèle ResNet-18 pré-entraîné atteint **97,9 % d'exactitude** sur des données inconnues.

Ces résultats valident la faisabilité technique d'un système automatique d'identification des devises congolaises et posent les bases directes du Projet Intégrateur (TP8).