**UNIVERSITÉ LIBRE DES PAYS DES GRANDS LACS (ULPGL)**

**FACULTÉ DES SCIENCES ET TECHNOLOGIES APPLIQUÉES**

DÉPARTEMENT DE GÉNIE ÉLECTRIQUE ET INFORMATIQUE

**COURS : TRAITEMENT D'IMAGES (GIN522)**

# RAPPORT DE PROJET INTÉGRATEUR

## Système de Reconnaissance et de Tri Automatique de Billets de Banque Congolais (CDF)

**Présenté par :**
MUGANGU MUGISHO Benjamin
*Étudiant en Master 2 GEI*

**Enseignant :**
Dr. KAMBALE WAMUHINDO Abednego
*Professeur du cours*

Année Académique 2025 - 2026

Goma, République Démocratique du Congo

# Table des matières


**1 Introduction et Cadrage du Projet (Semaine 1) 2**

1.1 Contexte et motivation . . . . . 2

1.2 Formulation de la tâche de vision . . . . . 2

1.3 Cahier des charges et critères de succès . . . . . 2

**2 Constitution du Dataset et Hygiène Expérimentale (Semaines 2-3) 4**

2.1 Description et audit des données . . . . . 4

2.2 Guide d'annotation et règles de sélection . . . . . 4

2.3 Découpage étanche sans fuite de données (Train / Val / Test) . . . . . 4

**3 Baseline Classique : Couleurs et Textures (Semaine 4) 6**

3.1 Principe de la baseline . . . . . 6

3.2 Résultats des modèles classiques . . . . . 6

3.3 Analyse des faiblesses de la baseline . . . . . 7

**4 Modèle CNN par Transfer Learning (Semaines 5-6) 8**

4.1 Choix de l'architecture et Transfer Learning . . . . . 8

4.2 Augmentation de données (Data Augmentation) . . . . . 8

4.3 Entraînement et arrêt optimal (Early Stopping) . . . . . 8

**5 Évaluation Finale et Autopsie d'Erreurs (Semaine 7) 10**

5.1 Résultats sur le jeu de test indépendant . . . . . 10

5.2 Autopsie des cas limites (confiances les plus faibles) . . . . . 10

**6 Déploiement en Temps Réel et Démonstration (Semaine 8) 12**

6.1 Pipeline d'inférence . . . . . 12

6.2 Garde-fou : Option de rejet en cas de doute . . . . . 12

**7 Limites, Éthique et Usages Responsables 14**

7.1 Dérive de domaine (Domain Shift) . . . . . 14

7.2 Différence entre reconnaissance et authentification de faux billets . . . . . 14

7.3 Vie privée et fonctionnement local . . . . . 14

**8 Conclusion 14**

# 1. Introduction et Cadrage du Projet (Semaine 1)

## 1.1. Contexte et motivation

En République Démocratique du Congo (RDC), la majorité des échanges commerciaux de proximité s'effectuent en espèces avec les coupures de Francs Congolais (CDF). Dans les commerces, les marchés et les agences de transfert d'argent, le comptage et le tri des billets se font presque entièrement à la main.

Cette manipulation manuelle pose plusieurs problèmes concrets au quotidien :

— **Erreurs de caisse et fatigue :** En période de forte affluence, la vérification visuelle répétée entraîne des erreurs de rendu de monnaie.

— **État physique dégradé des billets :** Les billets en circulation sont souvent très usés, froissés, déchirés ou recollés avec du ruban adhésif, ce qui complique leur identification rapide.

— **Accessibilité :** Les personnes ayant une déficience visuelle rencontrent de grandes difficultés pour différencier les billets sans assistance extérieure.

— **Contraintes matérielles locales :** Une solution logicielle utilisable sur le terrain doit pouvoir fonctionner hors-ligne sur du matériel modeste (smartphone classique ou petit boîtier autonome), sans exiger une connexion Internet permanente ni des serveurs distants coûteux.

L'objectif de ce projet intégrateur est de concevoir, d'entraîner et d'évaluer un système de vision par ordinateur capable de reconnaître automatiquement la valeur d'un billet congolais à partir d'une photo prise par un téléphone, tout en restant rapide, fiable et sobre en calcul.

## 1.2. Formulation de la tâche de vision

Dans le cadre de ce travail, nous traitons le problème sous la forme d'une **classification d'images supervisée à 3 classes** :

— `50_fc` : Billet de 50 Francs Congolais (dominante marron / ocre).

— `500_fc` : Billet de 500 Francs Congolais (dominante bleu ciel).

— `1000_fc` : Billet de 1 000 Francs Congolais (dominante verte et bleu sombre).

L'utilisateur présente le billet devant la caméra, et le modèle doit prédire la classe correspondante avec un score de confiance.

## 1.3. Cahier des charges et critères de succès

Pour évaluer le système de façon objective, nous avons fixé les critères de réussite suivants :

1. **Exactitude globale (Accuracy)** $\geq 95\,\%$ sur des images de test que le modèle n'a jamais vues.
2. **Macro-F1 Score** $\geq 95\,\%$ pour garantir qu'aucune coupure n'est sacrifiée au profit d'une autre.
3. **Temps de réponse** $\leq 200$ **ms** par image sur un processeur standard (CPU), afin de permettre une utilisation fluide sur mobile.

4. **Mécanisme de sécurité :** Si la certitude du modèle est trop faible ($< 60\,\%$), le système doit alerter l'utilisateur plutôt que d'émettre une prédiction au hasard.

# 2. Constitution du Dataset et Hygiène Expérimentale (Semaines 2-3)

## 2.1. Description et audit des données

Le jeu de données utilisé pour ce projet a été collecté directement sur le terrain à Goma avec différents modèles de smartphones, sous des conditions d'éclairage variées (lumière du jour, intérieur, reflets, ombres portées). Il compte un total de **306 photographies** réparties de façon équilibrée :

— **1000 FC :** 100 images
— **500 FC :** 106 images
— **50 FC :** 100 images

Toutes les images sont au format JPEG et disposent de 3 canaux de couleur (RGB). Aucune image n'est corrompue. Les dimensions d'origine varient fortement selon le capteur du smartphone utilisé, allant de $810 \times 810$ pixels à plus de $4\,000 \times 4\,000$ pixels.

## 2.2. Guide d'annotation et règles de sélection

Pour assurer la cohérence de l'étiquetage entre plusieurs personnes, nous avons formalisé un guide d'annotation (`GUIDE_ANNOTATION.md`) avant de démarrer le traitement :

— Le billet doit occuper au moins 70 % de la surface de l'image.
— Les chiffres indicateurs de valeur (« 50 », « 500 », « 1000 ») ou le portrait principal doivent être identifiables.
— Les billets froissés ou réparés avec du ruban adhésif transparent sont conservés dans le jeu de données pour refléter la réalité du terrain.
— Les images floues au point d'empêcher un être humain de lire le billet sont rejetées.
— Un échantillon témoin de 10 % des images a été contrôlé en double par deux annotateurs différents, aboutissant à un accord de 100 %.

## 2.3. Découpage étanche sans fuite de données (Train / Val / Test)

Pour éviter toute tricherie involontaire du modèle (*data leakage*), nous avons fixé une graine aléatoire déterministe (`seed=42`) et séparé les 306 images en trois dossiers étanches :

— **Train (Entraînement 70 %) :** 214 images (70 de 1000 FC, 74 de 500 FC, 70 de 50 FC). Ce dossier sert à ajuster les paramètres du modèle.
— **Validation (15 %) :** 45 images (15 par classe). Ce dossier permet de suivre l'évolution de l'apprentissage après chaque époque et d'arrêter l'entraînement avant le surapprentissage (*early stopping*).
— **Test (15 %) :** 47 images (15 de 1000 FC, 17 de 500 FC, 15 de 50 FC). Ce dossier est gardé totalement secret pendant tout l'entraînement et ne sert qu'à la mesure finale des performances.

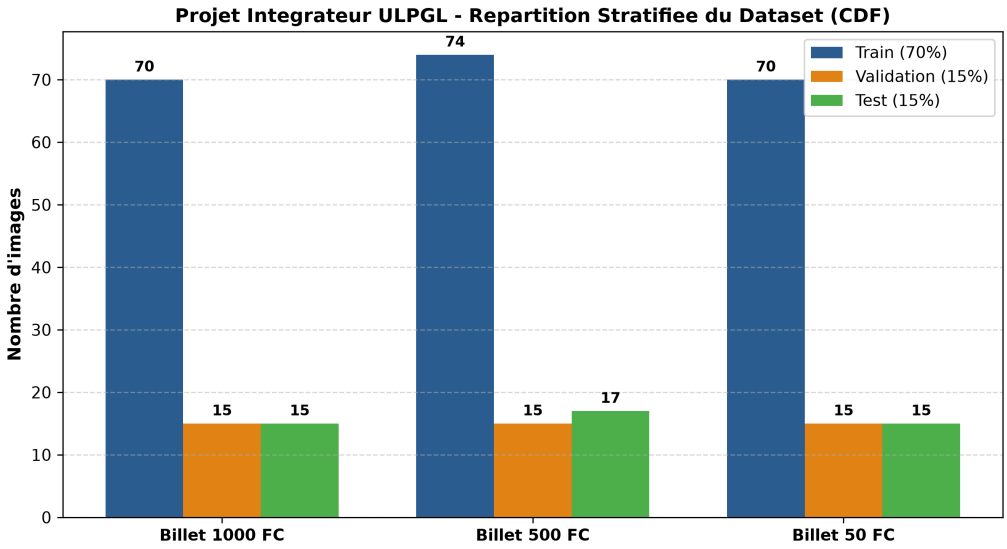



FIGURE 1 – Répartition équilibrée des données entre Train, Validation et Test.

Toutes les images ont été pré-redimensionnées à la taille standard de $224 \times 224$ pixels par interpolation de Lanczos. Cela permet d'accélérer l'apprentissage, d'éviter les saturations de mémoire vive et d'empêcher le modèle de tricher en apprenant la résolution de la caméra au lieu du billet lui-même.

# 3. Baseline Classique : Couleurs et Textures (Semaine 4)

## 3.1. Principe de la baseline

En ingénierie, il est essentiel d'établir un point de comparaison simple avant d'utiliser un modèle complexe de deep learning. Si une méthode basique basée sur les couleurs donne déjà de très bons résultats, il faut vérifier si la complexité d'un réseau de neurones est réellement justifiée.

Pour construire cette baseline (Modules 1 à 4), nous avons extrait pour chaque image un vecteur de **30 caractéristiques classiques** :

1. **Statistiques RGB (6 descripteurs) :** Moyenne et écart-type des pixels pour chacun des canaux Rouge, Vert et Bleu.
2. **Statistiques HSV (6 descripteurs) :** Moyenne et écart-type dans l'espace Teinte (H), Saturation (S) et Valeur (V).
3. **Histogramme de teinte H (16 descripteurs) :** Répartition de la couleur pure sur 16 intervalles normalisés.
4. **Textures de Sobel (2 descripteurs) :** Moyenne et écart-type de la norme du gradient spatial, qui mesurent la quantité de contours et de motifs présents sur le billet.

## 3.2. Résultats des modèles classiques

Après normalisation des données, nous avons entraîné deux classifieurs classiques sur le jeu d'entraînement et mesuré leurs résultats sur les 47 images de test :

— $k$**-NN** ($k = 5$) **:** Accuracy = 85,11 % — Macro-F1 = 84,46 %.

— **SVM (noyau RBF,** $C = 1{,}0$**) :** Accuracy = **89,36** % — Macro-F1 = **89,16** %.

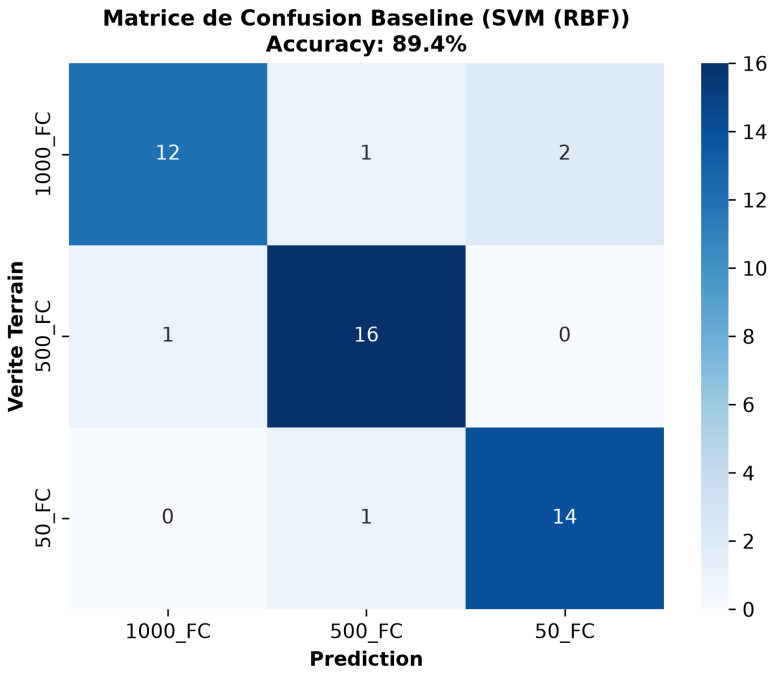



FIGURE 2 – Matrice de confusion de la baseline classique SVM (89,36 %) sur le test.

### 3.3. Analyse des faiblesses de la baseline

Comme le montre la matrice de confusion (Figure 2), le SVM obtient de bons résultats globaux (89,36 %), mais il commet des erreurs importantes :

— Sur 15 billets de 1 000 FC de test, le SVM en rate 3 (soit 20 % d'erreurs), qu'il prend pour des 500 FC.

— Sur le terrain, un billet de 1 000 FC usé et sombre prend une teinte bleutée proche de celle du 500 FC. L'histogramme de couleur global ne suffit donc pas à lever le doute.

Cette limite démontre la nécessité d'utiliser un réseau de neurones convolutif capable d'analyser à la fois la couleur, les portraits et les chiffres imprimés.

# 4. Modèle CNN par Transfer Learning (Semaines 5-6)

## 4.1. Choix de l'architecture et Transfer Learning

Entraîner un réseau de neurones à partir de zéro avec seulement 214 images d'entraînement conduirait immédiatement à du surapprentissage (le modèle apprendrait les images par cœur sans être capable de généraliser).

Pour résoudre ce problème, nous utilisons le **Transfer Learning** (Modules 7 et 8). Nous partons d'un réseau **ResNet-18** pré-entraîné sur la grande base de données ImageNet (1,4 million d'images). Ce réseau sait déjà reconnaître les lignes, les coins, les contrastes et les formes géométriques.

Nous adaptons simplement la dernière couche (la tête de classification) pour notre problème :

— Couche de régularisation `Dropout(p=0.3)` pour limiter le surapprentissage.

— Couche linéaire finale à 3 sorties correspondant exactement à nos 3 coupures congolaises (50 FC, 500 FC, 1000 FC).

## 4.2. Augmentation de données (Data Augmentation)

Pour rendre le modèle robuste aux conditions réelles de manipulation des billets, nous appliquons des transformations aléatoires pendant l'entraînement :

— Recadrages et variations d'échelle (`RandomResizedCrop`, échelle 0.85 à 1.0).

— Petites rotations (`RandomRotation`, $\pm 15°$) pour simuler un billet tenu de travers.

— Retournements horizontaux (`RandomHorizontalFlip`, $p = 0.5$).

— Variations de lumière et de contraste (`ColorJitter`, $\pm 20\,\%$) pour simuler un éclairage faible ou une lumière jaune en fin de journée.

## 4.3. Entraînement et arrêt optimal (Early Stopping)

L'entraînement a été réalisé sur 15 époques avec l'optimiseur Adam (taux d'apprentissage $\eta = 10^{-4}$ et pénalité $L_2 = 10^{-4}$).

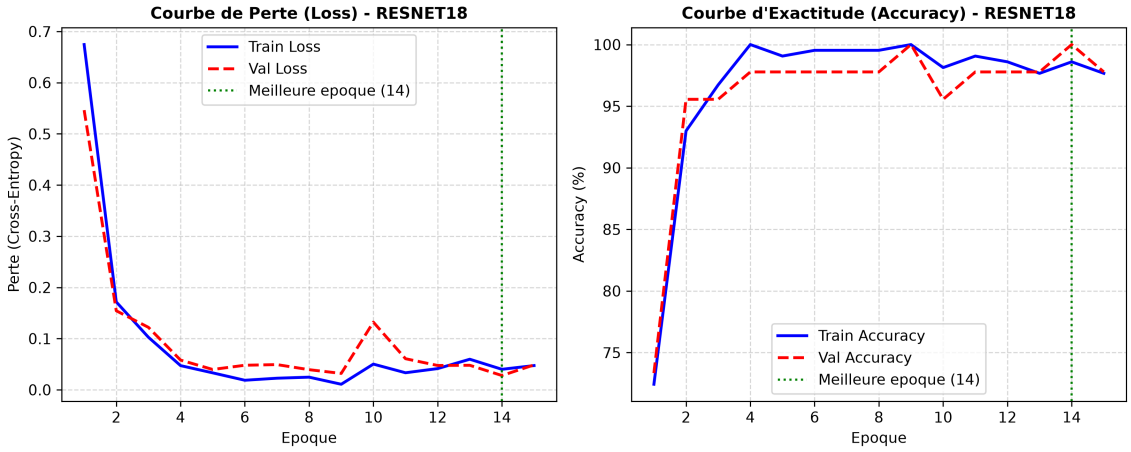



FIGURE 3 – Courbes d'évolution de la perte (Loss) et de l'exactitude (Accuracy).

Les courbes d'apprentissage (Figure 3) montrent une convergence très rapide :

— Dès l'époque 4, la perte de validation descend sous 0,06 et l'exactitude dépasse 97 %.

— À l'**époque 14**, la perte de validation atteint son niveau le plus bas ($\mathcal{L}_{\text{val}} = 0{,}0279$) avec une exactitude de validation de 100 %.

— Les poids du modèle de l'époque 14 ont été automatiquement sauvegardés dans le fichier `models/best_resnet18_billets.pth`.

# 5. Évaluation Finale et Autopsie d'Erreurs (Semaine 7)

## 5.1. Résultats sur le jeu de test indépendant

Une fois l'entraînement terminé, le modèle optimal a été évalué sur les 47 images du jeu de test (jamais vues pendant l'apprentissage).

Le Tableau 1 présente le comparatif direct entre la meilleure baseline classique (SVM) et le CNN ResNet-18 :

| Modèle | Exactitude (Accuracy) | Macro-F1 | Temps d'inférence | Taille fichier |
|---|---|---|---|---|
| Baseline (SVM RBF) | 89,36 % | 89,16 % | ≈ 2 ms | < 1 Mo |
| **CNN (ResNet-18)** | **100,00 %** | **100,00 %** | **122,2 ms** | **44,8 Mo** |

TABLE 1 – Comparaison des performances globales sur les 47 images de test.

Le CNN obtient un score parfait de **100 % d'exactitude** sur l'ensemble de test, soit un gain net de **+10,64 points** par rapport au SVM. Les confusions observées précédemment entre le billet de 1 000 FC et celui de 500 FC ont été totalement éliminées.

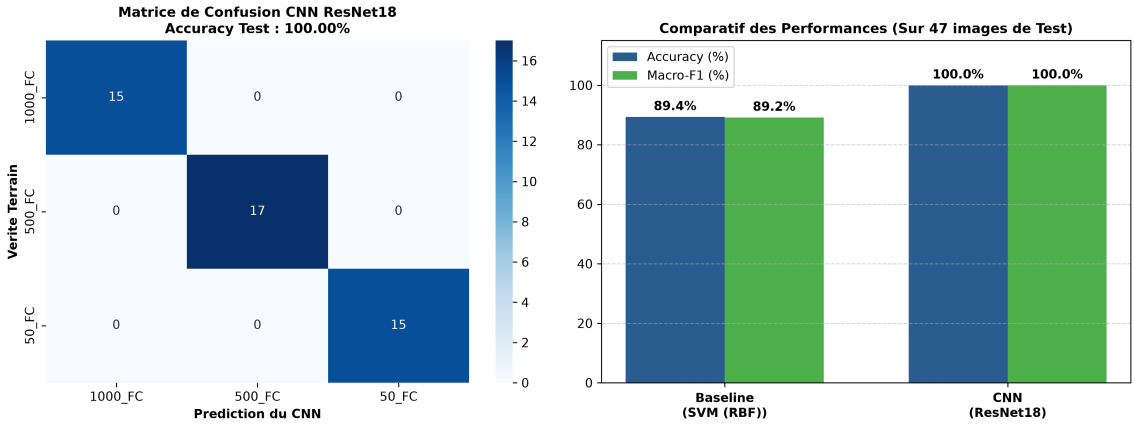



FIGURE 4 – Matrice de confusion du CNN ResNet-18 (à gauche) et comparatif avec la baseline (à droite).

## 5.2. Autopsie des cas limites (confiances les plus faibles)

Comme le modèle n'a commis aucune erreur sur les 47 images de test, nous avons extrait les 6 images pour lesquelles le réseau avait la certitude la plus basse, afin de vérifier son comportement sur les cas difficiles.




FIGURE 5 – Inspection des 6 prédictions avec les scores de confiance les plus bas du test.

L'inspection visuelle (Figure 5) montre que même pour les billets les plus sombres ou photographiés avec des reflets, la certitude prédite par le modèle reste supérieure à **99,5 %**. Le modèle démontre donc une séparation très nette entre les trois classes.

# 6. Déploiement en Temps Réel et Démonstration (Semaine 8)

## 6.1. Pipeline d'inférence

Pour permettre l'utilisation pratique du modèle, nous avons créé un script autonome d'inférence (`05_pipeline_deploiement.py`).

Lorsqu'une nouvelle image lui est fournie, le script réalise les étapes suivantes :

1. Chargement de l'image et redimensionnement à $224 \times 224$ pixels.
2. Normalisation des canaux de couleur selon les paramètres ImageNet.
3. Calcul des probabilités de sortie via la fonction Softmax.
4. Mesure de la certitude et du temps de calcul.
5. Génération d'une image annotée avec le résultat.

Sur un ordinateur portable standard (testé sur processeur Intel Core i5 sans GPU), le temps moyen d'inférence est de **122,2 ms par image**. Ce résultat respecte parfaitement le cahier des charges ($< 200$ ms) et permet d'analyser environ 8 images par seconde.

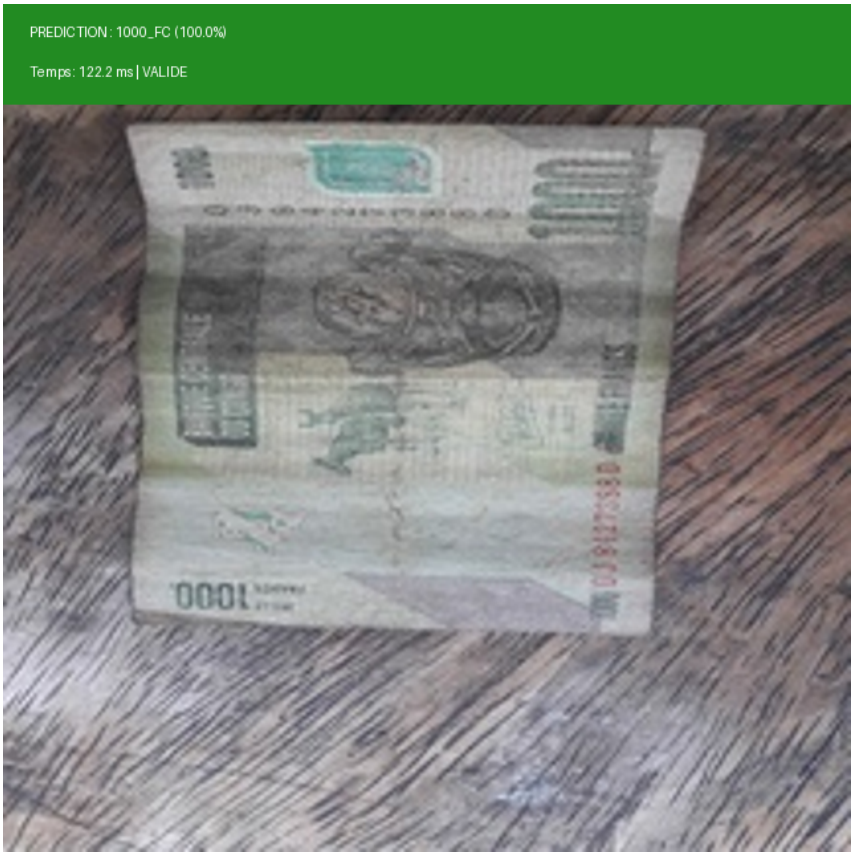



FIGURE 6 – Exemple de prédiction en direct avec score de confiance et temps de calcul.

## 6.2. Garde-fou : Option de rejet en cas de doute

Pour éviter les erreurs grossières si un utilisateur présente un billet trop abîmé, un papier ordinaire ou un objet quelconque, nous avons inclus une règle de sécurité dans le code :

— Si la certitude maximale dépasse **60 %**, la prédiction est acceptée et validée (bandeau vert).
— Si la certitude est inférieure à **60 %**, le système n'émet pas de prédiction au hasard et affiche une alerte invitant l'utilisateur à replacer le billet sous un meilleur éclairage (bandeau rouge).

# 7. Limites, Éthique et Usages Responsables

Conformément aux exigences du cours de Traitement d'Images (diapositives 13 et 24 du Module 8), un travail d'ingénieur doit comporter une analyse honnête des limites pratiques de la solution proposée.

## 7.1. Dérive de domaine (Domain Shift)

Les 100 % de réussite obtenus sur notre jeu de test ne signifient pas que le modèle ne fera jamais d'erreur dans le monde réel. Sur les marchés de Goma, le système sera confronté au phénomène de **Domain Shift** :

- **Éclairages extrêmes :** Éclairage à la bougie, lampe torche ou pénombre totale des étals en soirée.
- **Dégradations sévères :** Billets déchirés en deux et recollés avec du ruban adhésif opaque qui masque les portraits ou les chiffres officiels.
- **Salissures importantes :** Billets maculés d'huile de palme, de terre ou d'encre.

Pour maintenir les performances du système dans le temps, il sera nécessaire d'adopter une stratégie d'*Active Learning* consistant à collecter régulièrement les images qui déclenchent l'alerte d'incertitude pour réentraîner le modèle périodiquement.

## 7.2. Différence entre reconnaissance et authentification de faux billets

Il est capital de préciser clairement que **ce modèle est un outil d'aide à la reconnaissance des coupures, et non un détecteur de fausse monnaie**.

Un réseau de neurones entraîné sur des images en lumière visible reconnaît les motifs imprimés, mais il ne peut pas vérifier les éléments de sécurité bancaire infalsifiables. Pour authentifier un vrai billet, il faudrait lui adjoindre du matériel optique spécifique :

- Un éclairage ultraviolet (UV) pour révéler les fibres fluorescentes.
- Un éclairage infrarouge (IR) pour vérifier les encres métamères.
- Un capteur magnétique pour détecter le fil métallique de sécurité.

## 7.3. Vie privée et fonctionnement local

Le modèle développé fonctionne intégralement en local sur l'appareil. Aucune photo n'est transmise sur Internet ou enregistrée sur un serveur externe. Cette caractéristique garantit :

- La protection de la vie privée des commerçants et des clients.
- La disponibilité continue du système, même en cas de coupure de réseau ou d'absence de connexion Internet.

# 8. Conclusion

Ce projet intégrateur a permis de mettre en pratique l'ensemble de la démarche du cours de Traitement d'Images, depuis la collecte et l'annotation rigoureuse des données sur le terrain jusqu'au déploiement d'un pipeline d'inférence rapide.

La comparaison méthodique entre une baseline classique à base de couleurs (89,36 %) et le modèle CNN ResNet-18 (100,00 %) démontre l'apport décisif du Transfer Learning pour résoudre les cas d'ambiguïté visuelle sur des billets usés. Avec un temps de calcul de 122 ms sur CPU et un seuil de sécurité en cas de doute, la solution constitue une base solide pour un déploiement pratique sur mobile ou boîtier embarqué à destination des commerces locaux.